

# テキストマイニングの実践

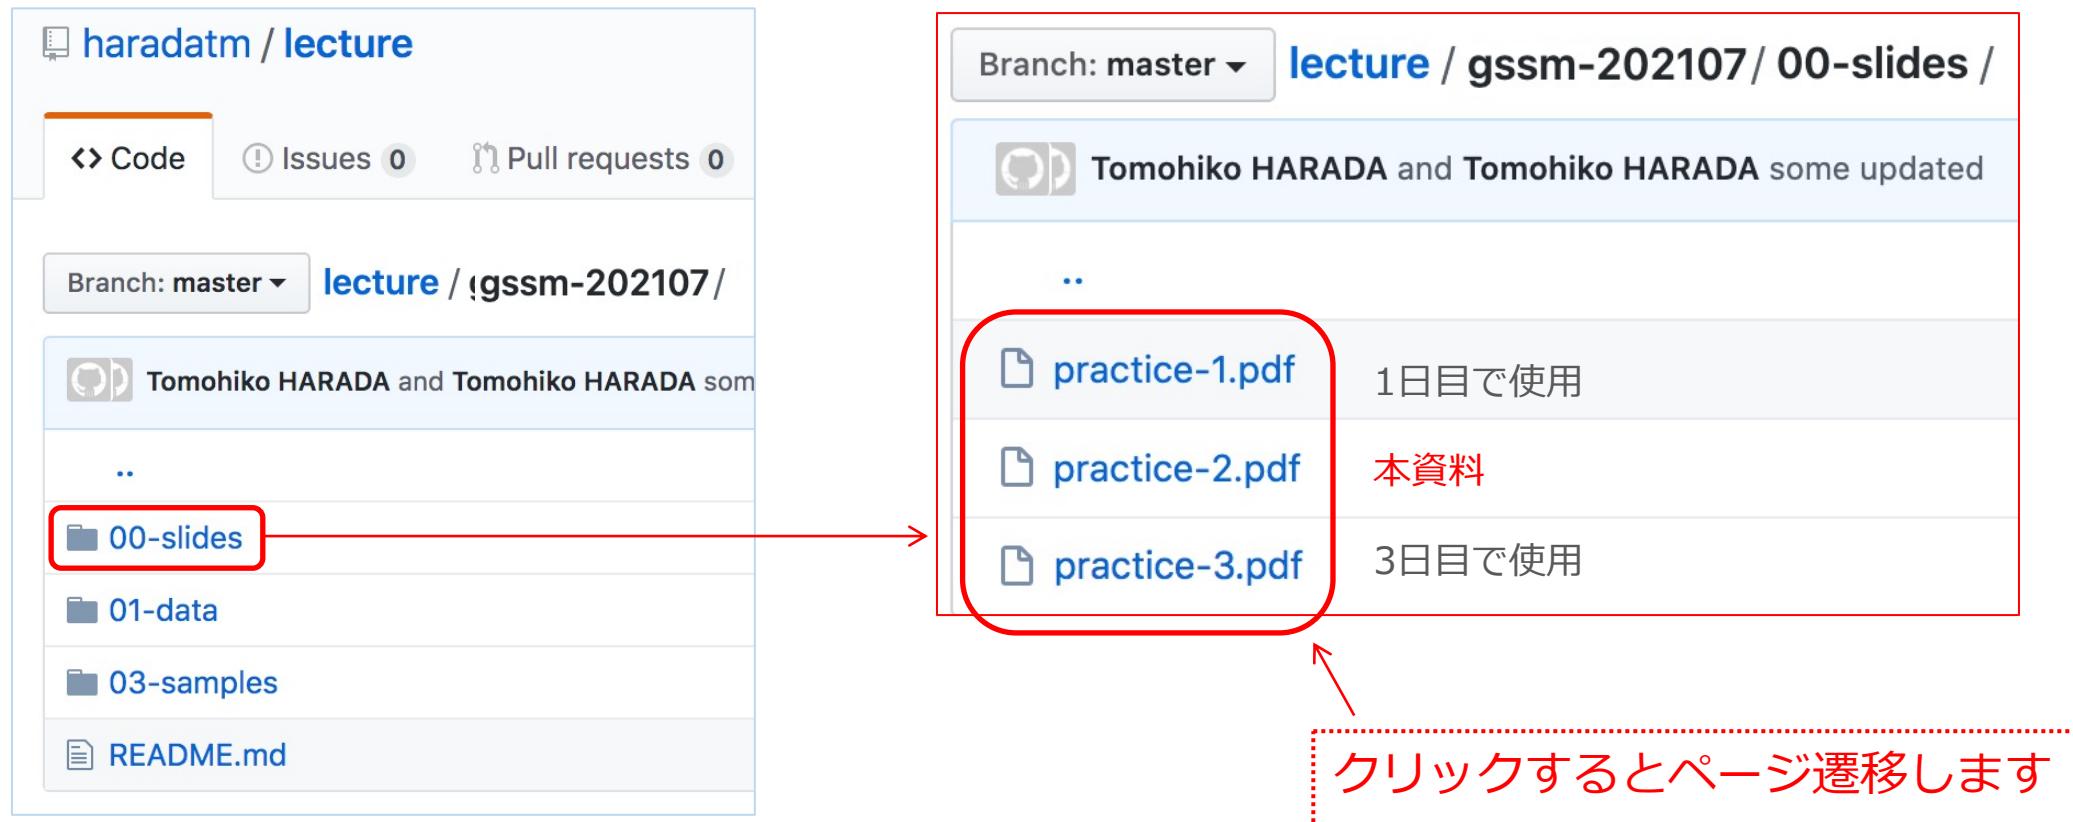
## — 2日目 —

2021/7/2

人文社会ビジネス科学学術院  
ビジネス科学研究群

# 講義スライド

- <https://github.com/haradatm/lecture/tree/master/gssm-202107>



# 自然言語処理のトレンド

# お話すること (2020年)

- ・**深層学習の発展とともに自然言語処理も進化**
  - ・応用タスクの学習データで End-to-end で学習可能
  - ・ブラックボックスのため、出力の解釈が難しい等の課題もある
- ・**自然言語処理研究の界隈では、BERT (Transformer) が席巻中**
  - ・テキスト分類、機械翻訳、質問応答(機械読解)、要約、文生成など様々な応用タスクの性能を向上
  - ・BERT 自体のブラックボックスを解明する “Bertology” も盛ん

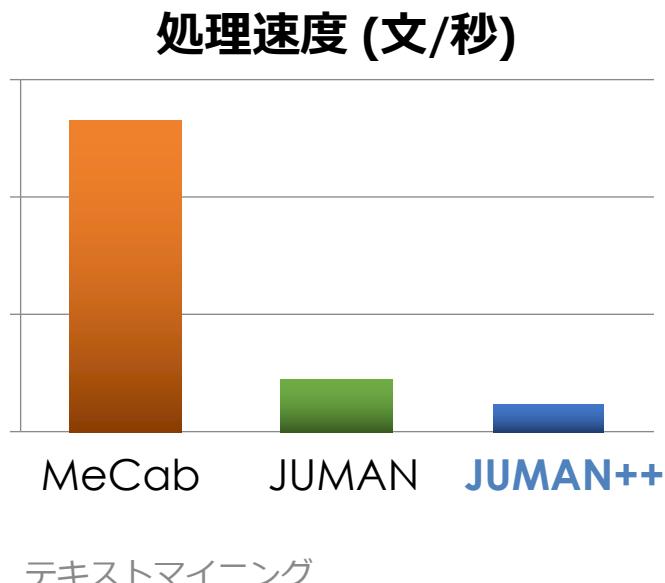
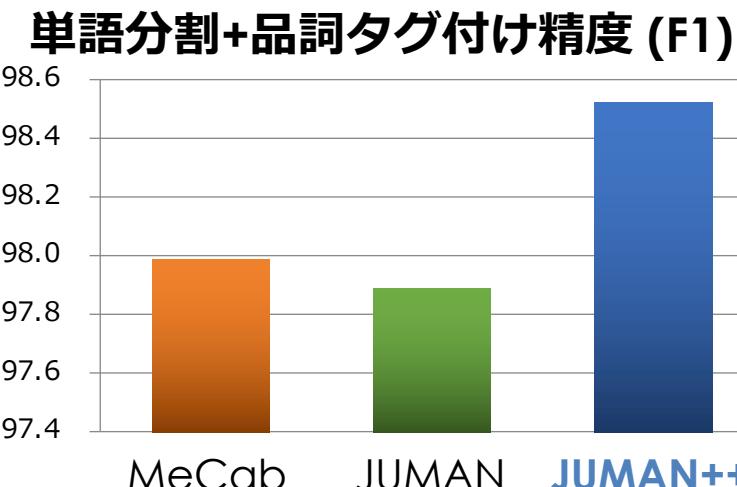
# お話すること

- ・**深層学習の発展とともに自然言語処理も進化**
  - ・応用タスクの学習データで End-to-end で学習可能
  - ・ブラックボックスのため、出力の解釈が難しい等の課題もある
- ・**自然言語処理研究を超えて Transformer が席卷中**
  - ・BERT (Transformer) テキスト分類、機械翻訳、質問応答(機械読解)、要約、文生成など様々な自然言語処理の応用タスクの性能を向上
  - ・GPT-3 などで使われている Transformer が、画像認識など自然言語処理以外の領域でも成果を発揮しつつある
- ・トレンドは 視覚+言語の事前学習モデル で、研究が盛ん

# 形態素解析器

出所: <https://taku910.github.io/mecab/> をもとに作成

形態素解析器	ChaSen	MeCab	JUMAN	JUMAN++
コスト推定	HMM	CRF	人手	RNNLM
探索方法	接続コスト最小法 (ビタビアルゴリズム)			
連携する構文解析器	Cabocha	Cabocha	KNP	<b>深層学習</b> を使った 手法で、 <b>自然な言葉</b> <b>の繋がり</b> を考慮



**学習・評価データ**  
京都大学テキストコーパス (NEWS),  
京都大学ウェブ文書リードコーパス (WEB)

**RNN言語モデルの学習**  
Webコーパス 1000万文

出所:  
[https://drive.google.com/file/d/1DVnrsWw4skRgC8jU6\\_RkeofOQEHFwctc/view?usp=sharing](https://drive.google.com/file/d/1DVnrsWw4skRgC8jU6_RkeofOQEHFwctc/view?usp=sharing)

# (参考) 形態素解析の辞書

辞書	JUMAN辞書	Ipadic (NAIST-jdic)	UniDic	NEologd
コーパス	京都大学テキスト コーパス	RWCコーパス <sup>*2</sup>	BCCWJ コアデータ <sup>*3</sup>	RWCコーパス
形態素解析器	JUMAN MeCab	Chasen MeCab	MeCab	MeCab
単語長	長い	やや短い	短い	とても長い

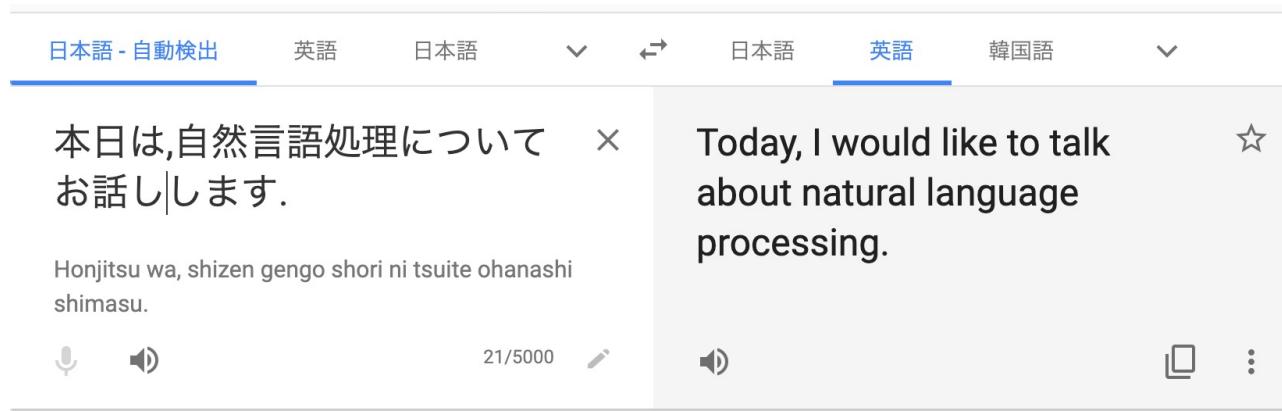
\*1 毎日新聞 1995年の記事や社説 4万文

\*2 旧通産省主導のプロジェクト,毎日新聞1994年3000記事 約3万7千文(約91万語)

\*3 現代日本語書き言葉均衡コーパス,国語研が中心となり開発,書籍,雑誌,新聞,Webなど,9万単語

# 自然言語処理

- 機械翻訳



- AIアシスタント



- 検索



自然言語をコンピュータで処理するための技術

# 自然言語処理

- 基礎タスク
  - 言語を応用タスクで利用しやすい形式に変換する  
例: 形態素解析(品詞タグ付け), 構文解析, 意味解析など
- 応用タスク
  - 自然言語処理を応用したアプリケーション  
例: 機械翻訳, 質問応答, テキスト要約, 対話システムなど


# 自然言語処理タスクの例

基礎タスク	形態素解析 (品詞タグ付け)	文をそれぞれの意味を担う最小の単位(=形態素)に分割し,それに品詞などの情報を付与する (例: MeCab, JUMAN++)
	構文解析	形態素解析で分割した単語同士の関連性を解析し,主に文節間の係り受け構造を発見しツリー化する, 文中の単語間の係り受け関係を調べ,どの単語がどの単語に係るのかを構文的に解析する <u>係り受け解析</u> (例: CaboCha, KNP, SpaCy) や, 語および文法的カテゴリを節点とするツリー形式によって文の構造を表現した <u>句構造解析</u> (例: Stanford Core NLP) がある
	意味解析	与えられた文のを明らかにする処理は何でも意味解析と呼ばれる, 格解析, 述語項構造解析, 多義性解消, 比喩理解 などが例として挙げられる
応用タスク	機械翻訳	自然言語によるある言語の文を入力とし,これを違う言語の文に翻訳する
	質問応答	自然言語による質問文を入力として受け取り,適切な回答を返す
	テキスト要約	与えられた文章を短く簡潔にまとめる, 文章の一部を抜粋して要約を作成する <u>抽出型要約</u> と,元の文章に存在しない文章で要約を作成する <u>抽象型要約</u> がある
	対話システム	自然言語により人間と機械が対話をを行う,チャットボットなどに使用されている


# トレンドは、深層学習の導入

- 大規模な訓練データで応用タスク全体を学習 → End-to-end 学習

従来の自然言語処理




深層学習による自然言語処理



坪井, 海野, 鈴木. 深層学習による自然言語処理. 講談社, 2017, p.4 の図を一部修正

# 深層学習 (ディープラーニング)

- ・ニューラルネットを用いた機械学習手法
  - ・機械学習とは、データを学習し、パラメータを獲得すること
  - ・脳の神経細胞(ニューロン)の働きを模した仕組みや構造のこと

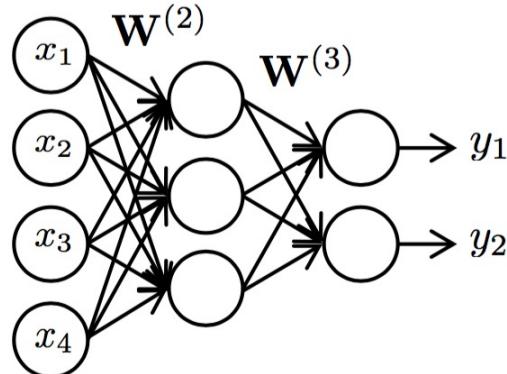


# ニューラルネットの歴史

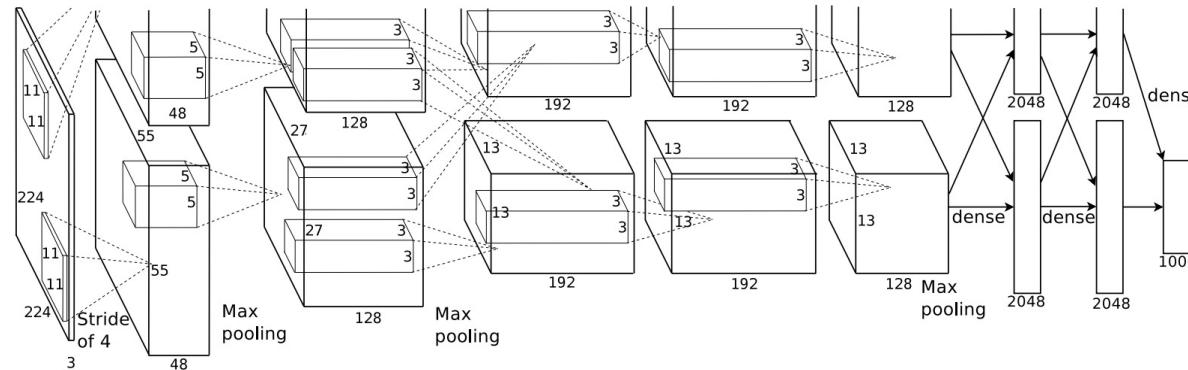
- 黎明～終焉を繰り返し,近年は3度目のブーム

第1期	1940～	• McCullochとPitts が形式ニューロンモデルを発表 [McCulloch-Pitts,43]
	1950～	• Rosenblatt がパーセプトロンを発表 [Rosenblatt,57]
	1960～	• MinskyとPapert が単純パーセプトロンの(線形分離不可能問題への)限界を指摘 [Minsky-Papert,69]
冬	1970～	冬の時代 (階層的構造の学習方法が未解決)
第2期	1980～	• Fukushima らがネオコグニトロンを提案 [Fukushima,80]
		• Rumelhart らが誤差逆伝播法を提案 [Rumelhart+,86]
		• LeCun らが畳み込みニューラルネット Conv.net を提案 [LeCun,89]
冬	1990～	冬の時代 (学習時間や過学習に課題, 一方でSVMが流行)
第3期	2000～	• Hinton らが事前学習とオートエンコーダを導入した多層NNを提案 [Hinton+,06]
	2010～	• Seide らが音声認識のベンチマークで圧勝 [Seide+,11] • Krizhevsky らがReLU を提案し画像認識コンペで圧勝 [Krizhevsky,12]

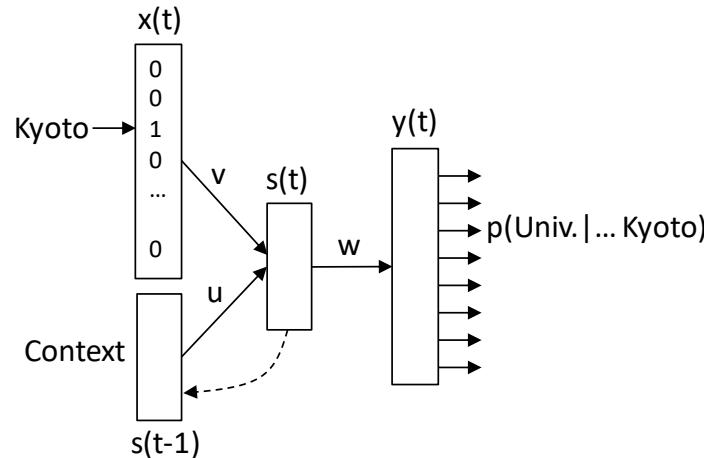
# 様々なニューラルネット




Feed forward NN



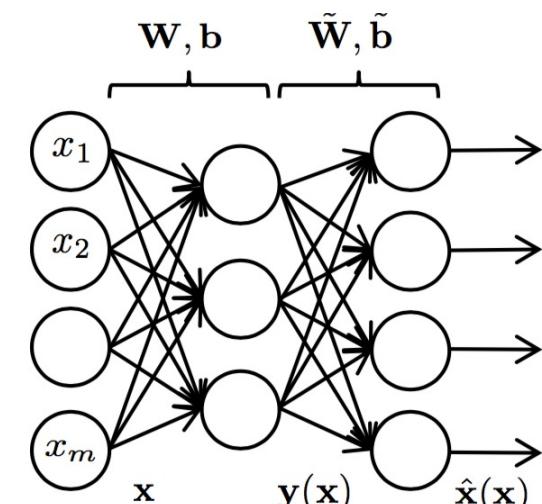
CNN (畳み込みNN)



RNN (Recurrent NN)



Recursive NN



AutoEncoder

# 音声認識で成功 [Seide+, 2011]



- Microsoft Research のグループ
  - 電話での会話音声の標準データセット
  - 入力(MFCC)-出力(HMM状態変数)の関係をDNNで学習
    - 従来 GMM-HMM → DNN-HMM (全結合7層, 事前学習あり)
  - 単語誤認識率で 10%前後の大幅な精度改善

acoustic model & training	recognition mode	RT03S		Hub5'00 SWB	voicemails		tele- conf
		FSH	SW		MS	LDC	
GMM 40-mix, ML, SWB 309h	single-pass SI	30.2	40.9	26.5	45.0	33.5	35.2
GMM 40-mix, BMMI, SWB 309h	single-pass SI	27.4	37.6	23.6	42.4	30.8	33.9
CD-DNN 7 layers x 2048, SWB 309h, this paper (rel. change GMM BMMI → CD-DNN)	single-pass SI	18.5 (-33%)	27.5 (-27%)	16.1 (-32%)	32.9 (-22%)	22.9 (-26%)	24.4 (-28%)

F. Seide, G. Li and D. Yu, "Conversational Speech Transcription Using Context-Dependent Deep Neural Networks." *Interspeech*. 2011.

# 画像認識で成功 [Krizhevsky+, 2012]

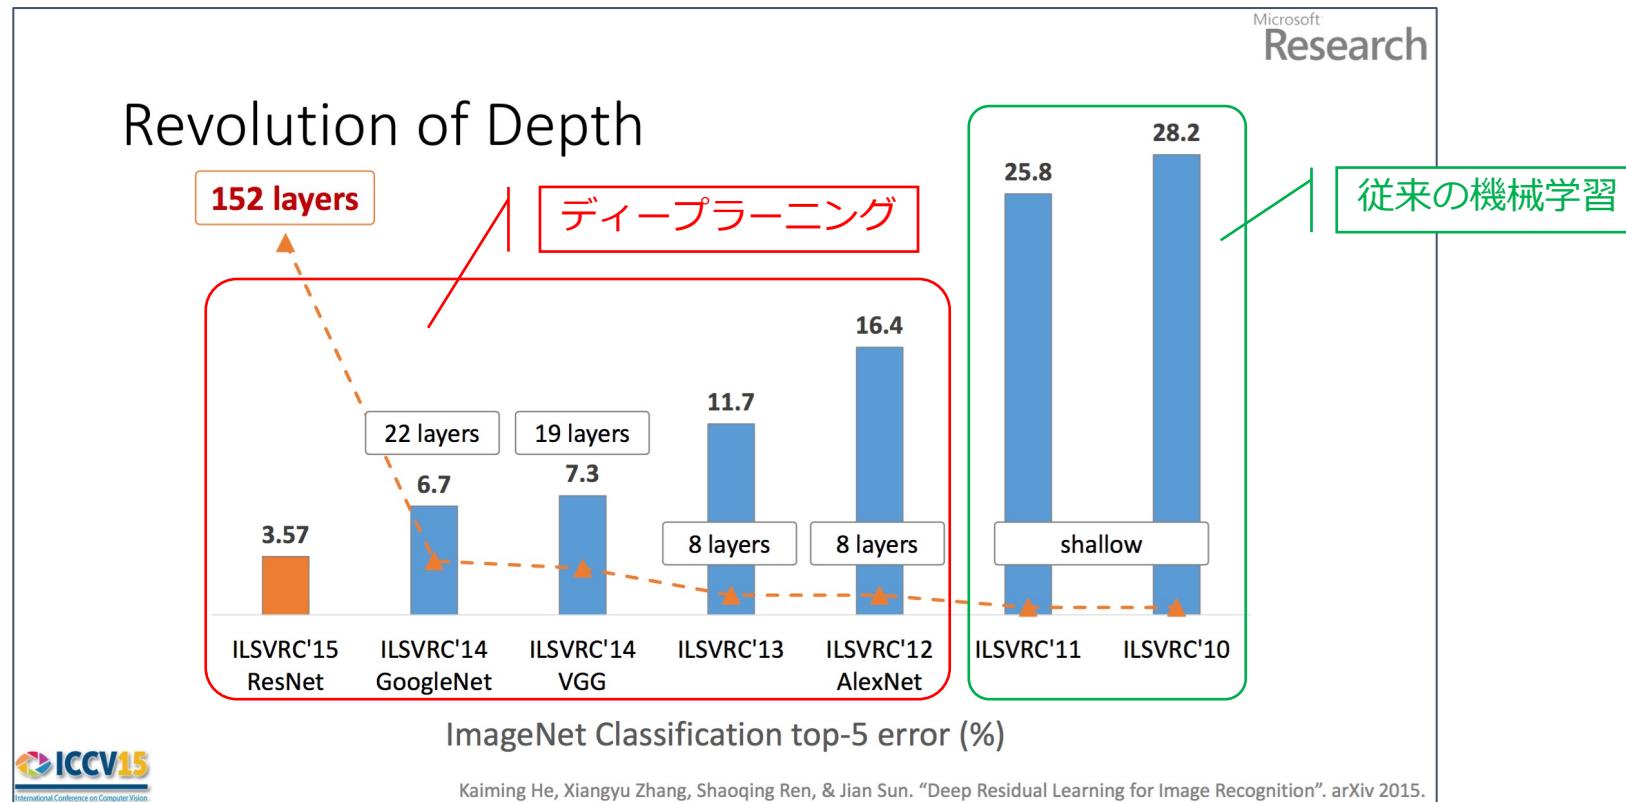
- ・一般物体認識 (Hintonのグループ)
  - ・ImageNet Large-scale Visual Recognition Challenge 2012
    - ・1000カテゴリ×約1000枚 = 100万枚 の訓練画像
    - ・畳込み層5, 全結合層3, 2つのGPUで2週間 (AlexNet)
    - ・誤識別率が10%以上減少 (過去数年間での向上は1~2%)



Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton.  
"Imagenet classification with deep convolutional neural networks."  
*Advances in neural information processing systems*. 2012.  
<http://image-net.org/challenges/LSVRC/2012/supvision.pdf>

# 画像認識における認識精度の変遷

- 2015年、人の認識精度(5.1%)を超えたことが話題に



# 深層学習 成功の背景

- 一定以上の規模のデータ → 改善
  - WebやIoT(センサ)などから十分な規模のデータを収集可能
- 学習の難しさ → 改善
  - 様々なテクニック (事前学習, dropout 等)
- 誤差逆伝搬法の計算量膨大 → 改善
  - 計算機能能力の飛躍的向上
  - GPU, マルチコアCPU, PCクラスタの登場
- 性能を引き出すのに必要なノウハウ → 未解決
  - 「黒魔術」のまま → **Explainable AI (説明可能AI)**として研究が盛ん

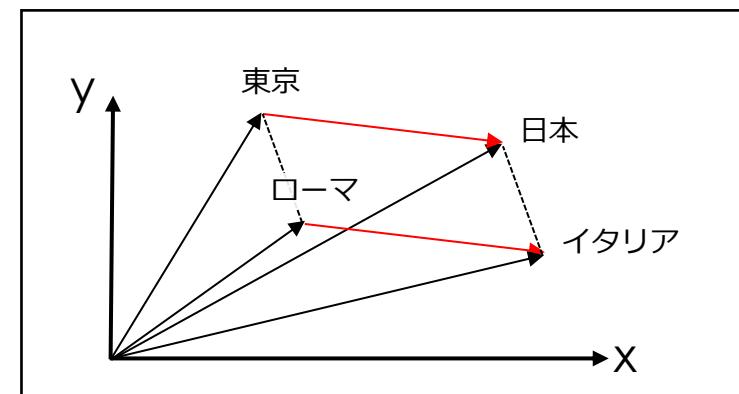
# 単語の分散表現 (=単語埋め込み)

- 単語のベクトル化 → 大規模コーパスによる事前学習


既存手法	近年→事前学習モデル
TF-IDF, Okapi BM25 など (分布的, 高次元, スパース)	word2vec, GloVe, fastText など (分散的, 低次元, 密)

- 代表格は「word2vec」
  - 深層学習による分布仮説のモデル化
  - $\text{king} - \text{man} + \text{woman} = \text{queen}$  で有名  
→ 右の例では、日本 - 東京 + ローマ = イタリア

Tomas Mikolov, Wen-tau Yih, Geoffrey Zweig, 2013, NAACL



# 事前学習モデルのタイムライン



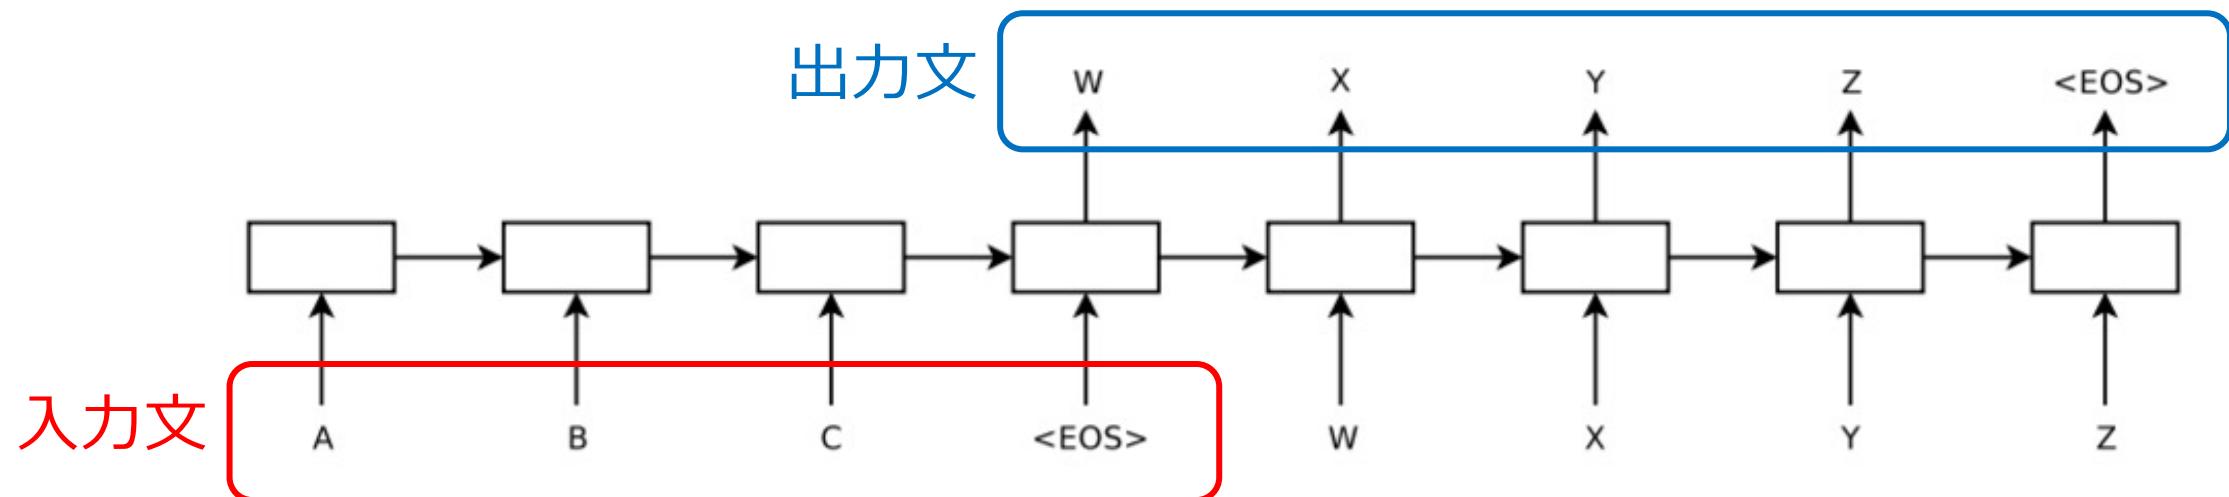
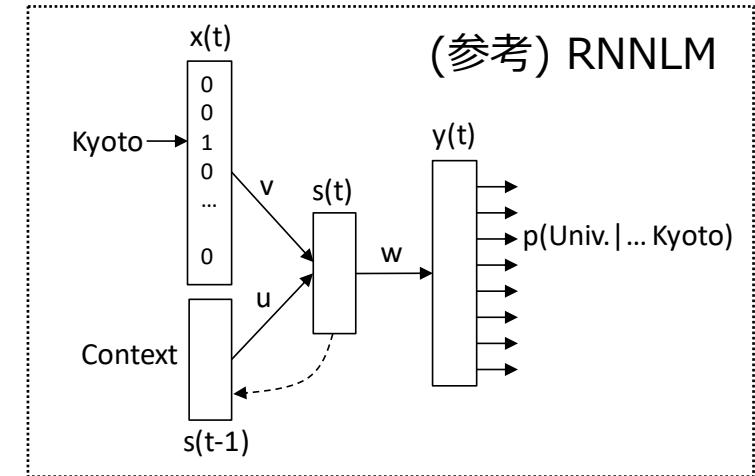
<https://towardsdatascience.com/2019-year-of-bert-and-transformer-f200b53d05b9>

# 深層学習の適用

分類	タスクの例	既存手法	深層学習による手法
基礎タスク	言語モデル	<ul style="list-style-type: none"><li>• N-gram</li></ul>	<ul style="list-style-type: none"><li>• Recurrent NN (RNNLM)</li></ul>
	分散表現	<ul style="list-style-type: none"><li>• TF-IDF</li><li>• Okapi BM25</li></ul>	<ul style="list-style-type: none"><li>• word2vec → <b>BERT</b></li></ul>
	品詞タグ付け	<ul style="list-style-type: none"><li>• CRF</li><li>• SVM</li></ul>	<ul style="list-style-type: none"><li>• Encoder-Decoder → <b>BERT</b> ※ Seq2Seq や Attention機構を含む</li></ul>
応用タスク	文書分類	<ul style="list-style-type: none"><li>• TF-IDF</li><li>• Okapi BM25</li></ul>	<ul style="list-style-type: none"><li>• Recurrent NN ※前の語を考慮</li><li>• Recursive NN ※木構造を考慮</li><li>• Convolutional NN ※付近の語を考慮</li></ul> <p>} → <b>BERT</b></p>
	機械翻訳	<ul style="list-style-type: none"><li>• 統計的機械翻訳</li></ul>	<ul style="list-style-type: none"><li>• Encoder-Decoder → <b>Transformer</b> ※ 対訳コーパスを end-to-end で学習する</li></ul>
	文書要約	<ul style="list-style-type: none"><li>• SVM</li><li>• 最大被覆問題</li></ul>	<ul style="list-style-type: none"><li>• Encoder-Decoder → <b>Transformer</b> ※ 原文と要約文を end-to-end で学習する</li></ul>

# Transformer 以前


- ニューラル機械翻訳の基本となったモデル
  - Seq2Seq [Sutskever+, NIPS2014]



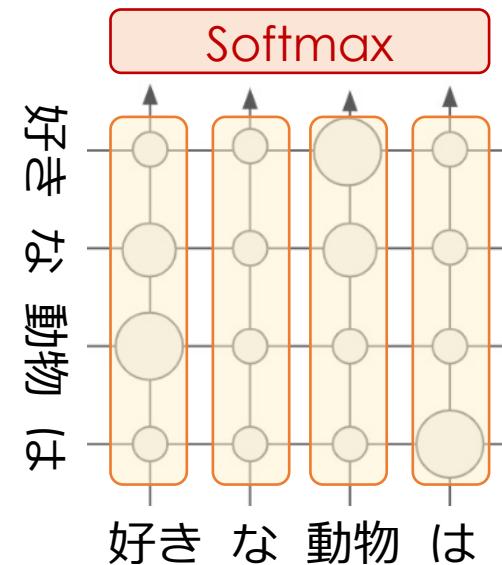
“ABC”という単語列から“WXYZ”という単語列への翻訳

# Transformer [Vaswani+,2017]

- RNNやCNNを使わずアテンションのみ使用した Transformer がニューラル機械翻訳で圧倒的な SOTA を達成
  - 従来、単語系列の文脈理解は主にLSTM → 長期依存性の理解に限界
  - 離れた単語の関係性も直接考慮できる Self-Attention が性能向上に大きく寄与した (しかも省メモリで計算可)




Self-Attention  
遠く離れた単語も  
直接関係性を考慮できる




# Transformer [Vaswani+,2017]

- 例: レイヤーN=6, ヘッドh=8, 長さ=512, 中間層=768



$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$



$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$


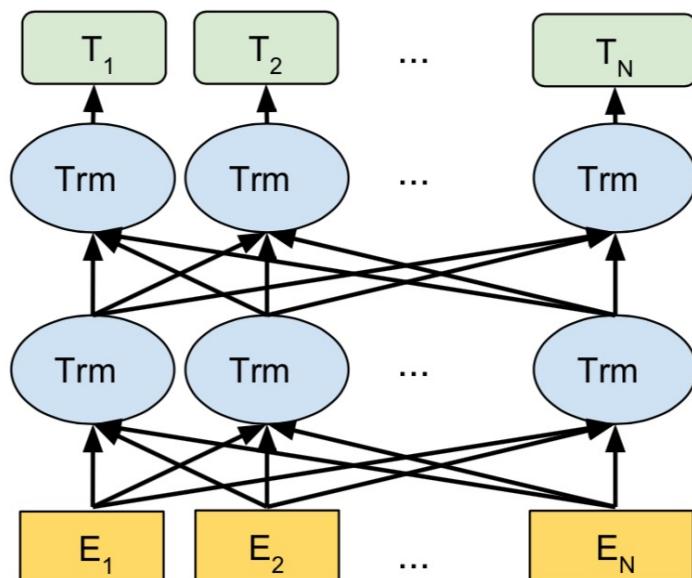


Figure 1: The Transformer - model architecture.

# BERT [Devlin+,2018]

- 双方向 Transformer ブロックを24層重ねた言語モデル
- 事前学習モデルが公開

BERT (Ours)



- 英語
  - 本家 Google の事前学習モデル \*1
  - Book Corpus 8億語 + 英語 Wikipedia 25億語 (語彙数 3万)
- 日本語
  - 黒橋研の事前学習モデル \*2
  - 日本語 Wikipedia 約1,800万文 (語彙数 3.2万)

\*1 <https://github.com/google-research/bert>

\*2 <http://nlp.ist.i.kyoto-u.ac.jp/index.php?BERT日本語Pretrainedモデル>

# 2018年10月: BERT の衝撃

- タスクに特化した構造を持たずに,人間のスコアを大きく超えた

## SQuAD1.1 Leaderboard

Since the release of SQuAD1.0, the community has made rapid progress, with the best models now rivaling human performance on the task. Here are the ExactMatch (EM) and F1 scores evaluated on the test set of SQuAD v1.1.

Rank	Model	EM	F1
	Human Performance <i>Stanford University</i> (Rajpurkar et al. '16)	82.304	91.221
1	BERT (ensemble) <i>Google AI Language</i> <a href="https://arxiv.org/abs/1810.04805">https://arxiv.org/abs/1810.04805</a>	87.433	93.160
2	BERT (single model) <i>Google AI Language</i> <a href="https://arxiv.org/abs/1810.04805">https://arxiv.org/abs/1810.04805</a>	85.083	91.835
2	nlnet (ensemble) <i>Microsoft Research Asia</i>	85.356	91.202

<https://rajpurkar.github.io/SQuAD-explorer/>

- 機械読解タスク(左)で,完全一致と部分一致の両指標で最高精度(2018/10/5)
- 様々な自然言語理解タスクでSOTA (QA,含意,言い換え,NER等)
- タスク適応は,出力層をタスク毎に1層のみ追加してfine-tuning

# 文脈を考慮した表現

- 文脈を考慮することで、様々なタスクの性能が向上

文脈に関係なく 一つの単語には一つのベクトルが割り当てられる	周りの文脈によって 同じ単語でも異なるベクトルが割り当てられる
<p>首を痛める</p> <p>首 </p> <p>会社を首になる</p> <p>首 </p>	<p>首を痛める</p> <p>首 </p> <p>会社を首になる</p> <p>首 </p>

# BERT Pre-train モデル

モデル	英語 モデル		日本語 モデル
	Base	Large	
公開元	Google Research <sup>*1</sup>		京大 黒橋研 <sup>*2</sup>
コーパス	Book Corpus 8億ワード + 英語Wikipedia 25億 ワード		日本語 Wikipedia 約1,800万文 (半角を全角に正規化)
語彙 (サブワード含む)	30K (WordPiece)		32K (Juman++ & BEP)
入力長	最大 512トークン <sup>*3</sup>		最大 128トークン <sup>*3</sup>
パラメタ	12層, 各層768次元	24層, 各層1024次元	12層, 各層768次元 (Base と同じ)
学習時間	4 Cloud TPUs で 4日間(≈100時間)	16 Cloud TPUs で 4日間(≈100時間)	1GPU (GTX 1080 Ti) で 約30日間(≈750時間)

<sup>\*1</sup> <https://github.com/google-research/bert>

<sup>\*2</sup> <http://nlp.ist.i.kyoto-u.ac.jp/index.php?BERT日本語Pretrainedモデル>

<sup>\*3</sup> 入力できるシーケンスの長さに制限があることに注意

# HuggingFace's Transformers

- Huggingface が提供する Pytorch によるフレームワーク
- 簡単にBERTなどの汎用言語モデルを動かせる

README.md

**Transformers**

build passing license Apache-2.0 website online release v2.3.0

State-of-the-art Natural Language Processing for TensorFlow 2.0 and PyTorch

Transformers (formerly known as `pytorch-transformers` and `pytorch-pretrained-bert`) provides state-of-the-art general-purpose architectures (BERT, GPT-2, RoBERTa, XLM, DistilBert, XLNet, CTRL...) for Natural Language Understanding (NLU) and Natural Language Generation (NLG) with over 32+ pretrained models in 100+ languages and deep interoperability between TensorFlow 2.0 and PyTorch.

**Features**

- As easy to use as `pytorch-transformers`
- As powerful and concise as Keras
- High performance on NLU and NLG tasks
- Low barrier to entry for educators and practitioners

State-of-the-art NLP for everyone

- Deep learning researchers
- Hands-on practitioners
- AI/ML/NLP teachers and educators

東北大から  
MeCab Tokenize  
の pre-trained モ  
デルも提供

README.md

Hugging Face  
@huggingface

おはようございます、日本の友達

Hello, Friends from Japan 🇯🇵!

Thanks to @NlpTohoku, we now have a state-of-the-art Japanese language model in Transformers, `bert-base-japanese`.

Can you guess what the model outputs in the masked LM task below?

```
import torch
from transformers import BertForMaskedLM
from transformers import BertJapaneseTokenizer
model = BertForMaskedLM.from_pretrained('bert-base-japanese')
tokenizer = BertJapaneseTokenizer.from_pretrained('bert-base-japanese-whole-word-masking')
model.eval()

input_ids = tokenizer.encode("山田さんはがtokenizer.mask_token)を見たのはこれが初めてでした。巨大だった。",
...; return_tensors='pt')

# This was the first time for Mr. Yamada to see [MASK]. It was huge.

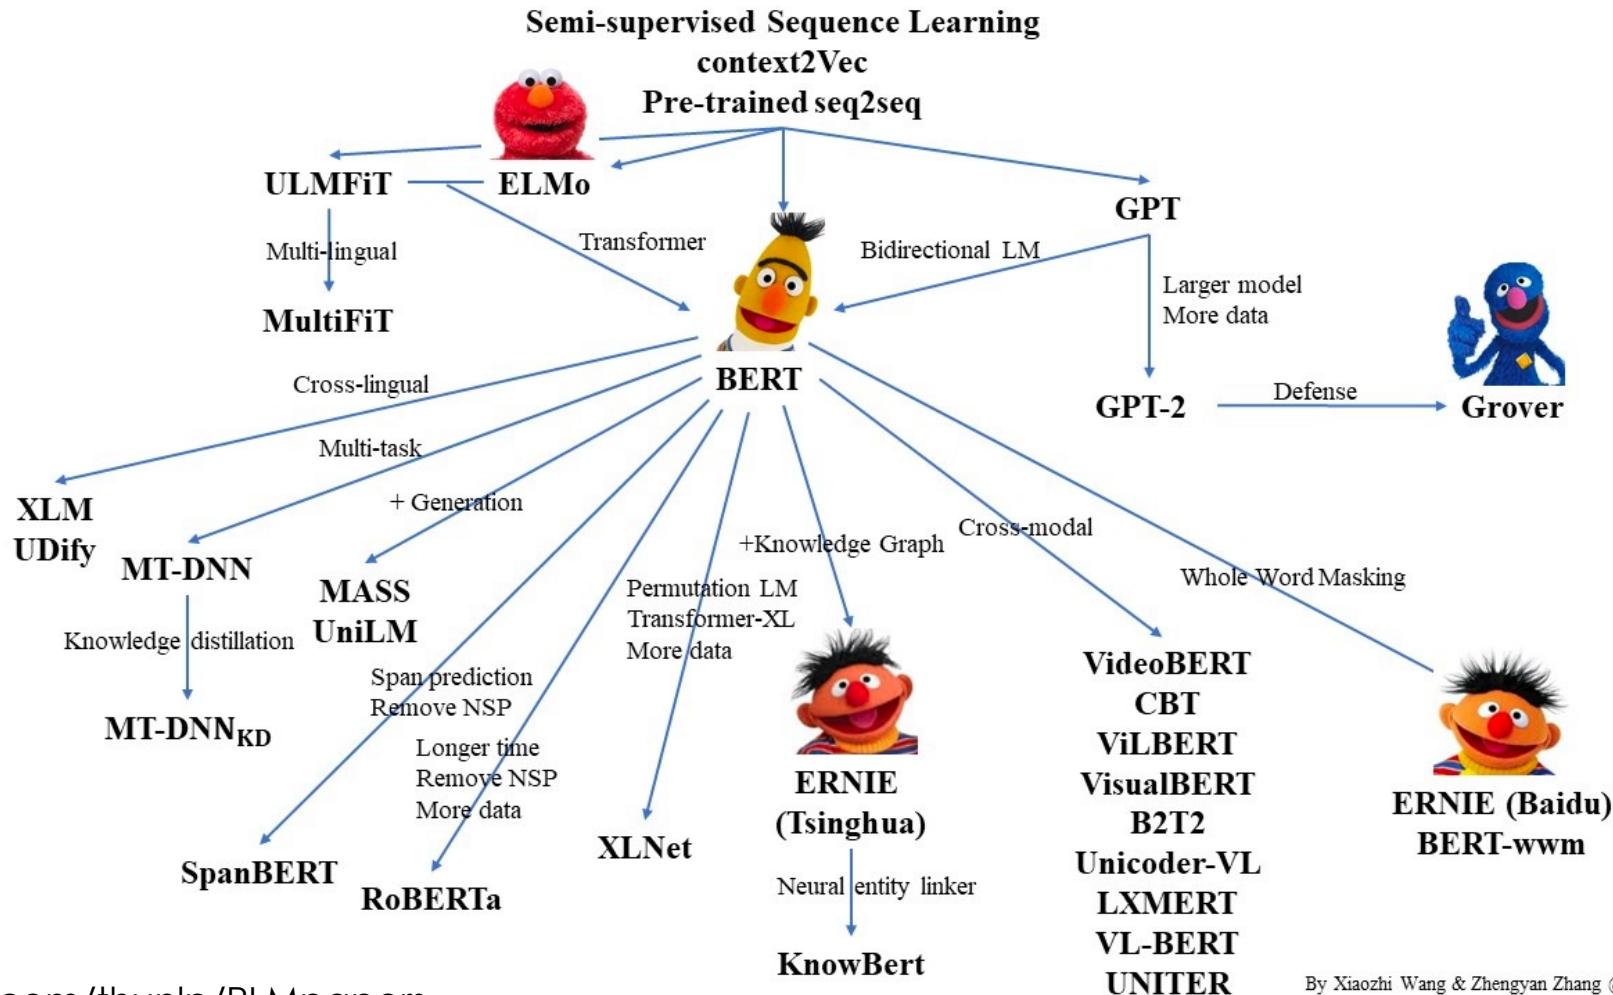
masked_index = torch.where(input_ids == tokenizer.mask_token_id)[1].tolist()[0]

result = model(input_ids)
result = result[0][1], masked_index.topk(5).indices.tolist()[0]
for r in result:
    output_ids = r[1].tolist()
    output(masked_index) + r
    print(tokenizer.decode(output))

# [CLS] 山田 さん が ゴラク を 見た の は これ が 初めて で し た 。 巨大 だ っ た 。 [SEP]
# [CLS] 山田 さん が 瞬間 を 見た の は これ が 初めて で し た 。 巨大 だ っ た 。 [SEP]
# [CLS] 山田 さん が それ を 見た の は これ が 初めて で し た 。 巨大 だ っ た 。 [SEP]
# [CLS] 山田 さん が 露天山 を 見た の は これ が 初めて で し た 。 巨大 だ っ た 。 [SEP]
```

テキストマイニング

# 1年以内に,BERT 改良モデルが続々登場



# GPT-3 [Brown+ (OpenAI), 2020]

- ・前身のGPT-1<sub>(1億)</sub>, GPT-2<sub>(15億)</sub>と同様に自己回帰言語モデル<sub>(1,750億)</sub>
- ・タスクの説明もテキストとして入力し, マルチタスクを実現
- ・少数のデモンストレーションに基づく転移学習が可能
  - ・ **Few-shot**: 学習後はパラメータを更新せず, 推論時にタスク説明と少数(10から100)のデモンストレーションを与える
  - ・ **One-shot**: タスク説明と1つのデモンストレーションを与える
  - ・ **Zero-shot**: タスク説明のみ与え全くデモンストレーションを与えない

## The three settings we explore for in-context learning


### Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.




### One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.



### Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.




The screenshot shows the OpenAI Playground interface. At the top, there are links for 'OpenAI Beta', 'Playground', 'Documentation', and 'Examples'. Below this, the title 'Playground' is displayed with a help icon. A list of Japanese-to-Hiragana translations is shown:

- 西暦から和暦に変換します。
- 西暦2021年 => 令和3年
- 西暦1967年 => 昭和42年
- 西暦1900年 => 明治33年
- 西暦1853年 => 光熱元年
- 西暦1804年 => 慶安元年
- 西暦1733年 =>

# Vision Transformer (ViT) [Dosovitskiy+, 2021]

- Transformer は画像認識などの NLP 以外でも成果を発揮



- 画像パッチを単語とみなす 632M の Transformer エンコーダ
- 画像は最初にパッチに分割した後、線形変換で埋め込み
- 3億枚以上の画像分類で事前学習し、ImageNet 等で SOTA

[https://github.com/google-research/vision\\_transformer](https://github.com/google-research/vision_transformer)

# DALL・E [Radford+ (OpenAI), 2021]

- OpenAI が発表した文章に忠実な画像を生成するモデル

TEXT PROMPT  
チュチュを着た赤ちゃん大根が犬を散歩させている

AI-GENERATED IMAGES



Edit prompt or view more images ↓

TEXT PROMPT  
アボカドの形をした肘掛け椅子

AI-GENERATED IMAGES



Edit prompt or view more images ↓

文字を含む画像も生成できている

- 巨大な Transformer デコーダ による Text-to-image モデル
  - パラメタ数は最大12B (ViT の約20倍)
- 大量の画像と説明文ペアから学習、生成画像のレベルが高い
- 画像は1024(32x32)のコード系列(8192種)として扱う

<https://openai.com/blog/dall-e/>

# CLIP [Radford+ (OpenAI), 2021]

- 大規模な画像とテキストのペアで zero-shot の物体認識を実現



- 画像とテキストのマッチングを4億ペアから事前学習
  - DALL·E の生成画像のランキングにも使われている
- 正しい画像・テキストペアを分類できるように Contrastive pre-training を行う

<https://openai.com/blog/clip/>

# まとめ

- ・ **深層学習の発展とともに自然言語処理も進化**
  - ・ 応用タスクの学習データで End-to-end で学習可能
  - ・ ブラックボックスのため、出力の解釈が難しい等の課題もある
- ・ **自然言語処理研究を超えて Transformer が席卷中**
  - ・ BERT (Transformer) テキスト分類、機械翻訳、質問応答(機械読解)、要約、文生成など様々な自然言語処理の応用タスクの性能を向上
  - ・ GPT-3 などで使われている Transformer が、画像認識など自然言語処理以外の領域でも成果を発揮しつつある
- ・ **トレンドは 視覚+言語の事前学習モデル** で、研究が盛ん

# スケジュール

- 1日目: 6/25(金)
    - 説明 — テキストマイニングの手順
    - 説明 — データをよく知る (Excel)
  - 2日目: 7/2(金)
    - 説明 — テキストマイニングツールの使い方 (KHCoder)
  - 3日目: 7/9(金)
    - 説明 — データ分析の実践 (KHCoder)
    - 実習 — データ分析の実践 (KHCoder) ←————— 3日目と5日目 は、Zoom のブレイクアウトルーム機能を使ったグループワークになります。
  - 4日目: 7/16(金)
    - Text Mining Studio 利用体験
  - **体育の日: 7/23(金)**
  - 5日目: 7/30(金)
    - 発表 — データ分析の実践 (KHCoder)

# (復習) テキストマイニングの手順

## ・データをよく知る

- ・データ件数や構成比を集計 → データを理解する
  - ・旅行目的別の人気エリアは?
  - ・同伴者別の人気エリアは?
  - ・数値評価による人気エリアの差異は?

## ・テーマを設定する

- ・解決すべき課題を決める → 分析目的を明確にする
  - ・数値評価が低い原因は?
  - ・高評価の施設に学ぶ改善点は?

## ・データ分析に取り組む

- ・これら課題を解決するために、テキスト分析を実施

# (復習) 使用するデータ

- ・ 楽天トラベルから収集した「お客様の声」のデータ
  - ・宿泊日が2019年、下記の10エリアが対象

レジャー	5エリア	登別, 草津, 箱根, 道後, 湯布院	1,000件×10エリア = 計10,000件
ビジネス	5エリア	札幌, 名古屋, 東京, 大阪, 福岡	

- ・データ項目

施設情報	4項目	カテゴリ, エリア, 施設番号, 施設名
口コミ	1項目	コメント
ユーザー評価	7項目	総合, サービス, 立地, 部屋, 設備・アメニティ, 風呂, 食事
その他の分類	2項目	旅行の目的, 同伴者
宿泊日	1項目	宿泊年月
ユーザー情報	3項目	ユーザー, 年代, 性別

## 鴨川シーワールドホテルのクチコミ・お客さまの声

[●ホテル・旅行のクチコミTOPへ](#)

## 総合評価

4.12


アンケート件数：886件

## 評価内訳

- 5点 ■■■■■ 236件
- 4点 ■■■■ 302件
- 3点 ■■ 47件
- 2点 ■ 15件
- 1点 ■ 9件

## 項目別の評価

サービス	4.11
立地	4.61
部屋	3.53
設備・アメニティ	3.62
風呂	3.53
食事	4.10



総合 2

## 投稿者さんの 鴨川シーワールドホテル のクチコミ（感想）



投稿者さん

2015年06月11日 17:03:57

良かったところ

- ・部屋からの景色（朝日最高でした）
- ・食事（品数が多く、朝夕とも良かったです）
- ・フロントの方の対応（お姉さんがとても頑張っていました）以上。

掃除が行き届いているとの口コミを多く見ましたが、それは思いませんでした。

気にかかることは多々ありましたが、フロントのお姉さんが一生懸命で、その笑顔に救われた思います。

## 評価

... 総合 2

- |          |   |
|----------|---|
| サービス     | 2 |
| 立地       | 4 |
| 部屋       | 4 |
| 設備・アメニティ | 2 |
| 風呂       | 2 |
| 食事       | 4 |

## 旅行の目的

... レジャー

## 同伴者

... 家族

## 宿泊年月

... 2015年06月

## 情報



鴨川シーワールドホテル

2015年06月11日 19:32:50

この度は、ご利用頂きまして誠にありがとうございます。

客室内清掃の件、大変申し訳  
重要改善として、早急に対応いたします。

今後は、この様な事の無いように、清掃・点検を  
強化いたします。

## テキストデータ

## フロントスタッフへのお言葉

誠にありがとうございます。

セラベーションアップに繋がる  
お客様からの声として、  
スタッフと共有させて頂きます。

## 数値評価

# (復習) データをよく知る

	データの特徴	テキスト分析時に注意すべきバイアス等
年代別・性別	<ul style="list-style-type: none"> <li>約60%が年代や性別を表明していない</li> <li>年代別では、目的によらず40~60代が多い</li> <li>全体的に男性の投稿者が多い（女性の倍以上）</li> <li>レジャーに比べてビジネス方が男女差が大きい</li> <li>レジャーの中でも男女差が大きいのは道後</li> </ul>	<ul style="list-style-type: none"> <li>レビュー観点がある年代や性別に偏っている可能性</li> <li>無回答(na)層がある年代や性別に偏っている可能性</li> </ul>
目的別	<ul style="list-style-type: none"> <li>レジャーは家族が多い、ビジネスは一人が多い（出張は単独）</li> <li>レジャーの中でも、道後は男性の一人客が多い（道後はもはや仕事で行く場所）</li> </ul>	<ul style="list-style-type: none"> <li>レビューの観点が性別によって偏っている可能性</li> <li>レビューの観点がカテゴリと一致していない可能性（道後→仕事）</li> </ul>
数値評価 (総合)	<ul style="list-style-type: none"> <li>旅行目的によらず評価は高め</li> <li>レジャーがビジネスより評価が高め</li> <li>レジャーの中で評価が高いのは湯布院、低いのは登別</li> <li>ビジネスの中で評価が高いのは札幌と大阪、低いのは東京都と福岡だが僅差</li> </ul>	<ul style="list-style-type: none"> <li>好評価しか投稿しない→コメントが好評価に偏っている可能性</li> <li>旅行目的によって投稿の動機が異なっている可能性</li> </ul>
数値評価 (項目ごと)	<ul style="list-style-type: none"> <li>レジャーの評価は、風呂や食事 &gt; 設備や部屋</li> <li>ビジネスの評価は、立地 &gt; その他</li> <li>レジャーの中で湯布院は軒並み高評価</li> <li>レジャーもビジネスも立地は高評価</li> </ul>	<ul style="list-style-type: none"> <li>旅行目的によって評価の観点や重みが異なっている可能性</li> </ul>
全体	<ul style="list-style-type: none"> <li>あくまでも楽天トラベルの特性であるので、旅行者一般として主張するには別途裏付けが必要</li> </ul>	

# (復習) データをよく知る

## 数値評価の平均 (エリア別)


行ラベル	平均 / サービス	平均 / 立地	平均 / 部屋	平均 / 設備・アメニ	平均 / 風呂	平均 / 食事	平均 / 総合
A_レジャー	4.16	4.20	4.04	3.98	4.22	4.22	4.23
01_登別	3.88	4.13	3.83	3.78	4.16	3.93	4.02
02_草津	4.12	4.29	3.95	3.87	4.25	4.15	4.22
03_箱根	4.18	4.07	4.04	3.97	4.19	4.27	4.19
04_道後	4.01	4.21	3.97	3.85	4.19	4.15	4.15
05_湯布院	4.60	4.29	4.43	4.19	4.27	4.57	4.57
B_ビジネス	3.91	4.24	3.98	3.85	3.69	4.08	4.08
06_札幌	3.95	4.20	4.01	3.81	3.66	3.88	4.10
07_名古屋	3.96	4.15	3.99	3.89	3.74	3.99	4.12
08_東京	3.85	4.33	3.91	3.81	3.67	3.91	4.04
09_大阪	3.92	4.32	3.91	3.81	3.67	4.02	4.13
10_福岡	3.85	4.21	3.91	3.81	3.67	3.90	4.00

## 数値評価の平均 (レジャー, ビジネス別)

行ラベル	平均 / サービス	平均 / 立地	平均 / 部屋	平均 / 設備・アメニ	平均 / 風呂	平均 / 食事	平均 / 総合
A_レジャー	4.16	4.20	4.04	3.98	4.22	4.22	4.23
B_ビジネス	3.91	4.24	3.98	3.85	3.69	3.94	4.08

# 全学計算機システムのリモートデスクトップ

- ・全学計算機システムのリモートデスクトップを使用します
  - ・【Win】 <https://www.u.tsukuba.ac.jp/remote/#win2win>
  - ・【Mac】 <https://www.u.tsukuba.ac.jp/remote/#mac2win>



上記のページにある説明に従って、全学計算機システム(**Windows**)へログインができますことを確認してください

## Mac の場合:

左記のページにある説明に従って、事前にツール **Microsoft Remote Desktop** のインストールが必要です

## KH Coder インストール時の注意:

全学の Windows の場合は、ログイン後の**デスクトップ上に「khcoder」というフォルダを作成**して、その中に解凍してください

# KH Coder のインストール

- ・ダウンロードとインストール <https://khcoder.net/dl3.html>



- ① ここをクリックすると遷移先のページからダウンロードが始まります
- ② 指示に従いインストール

自己解凍ファイルです。このファイルを実行（ダブルクリック）し、開いたWindowの「Unzip」ボタンをクリックすると、（特に変更しなければ）「C:¥khcoder3」というフォルダにすべてのファイルが解凍されます。

## 全学の Windows の場合の注意:

ログイン後のデスクトップ上に「khcoder」というフォルダを作成 or 「Z:¥khcoder」に解凍してください

# KH Coder —立命館の樋口先生が開発

- ・社会調査データを分析するために開発されたフリーのテキストマイニングツール

- ・高機能,商用可能でフリー
- ・Rを用いた多変量解析と可視化
- ・実装されている分析手法
  - ・階層的クラスター分析
  - ・多次元尺度構成法(MDS)
  - ・対応分析
  - ・共起ネットワーク
  - ・自己組織化マップ
  - ・文書のクラスター分析

論文検索サービスも提供 →

<http://khcoder.net/bib.html?year=2018&auth=all&key=>

## 研究事例リスト

KH Coderを用いたご研究の成果を発表された際には、書誌情報をフォームにご記入いただけますと幸いです。

出版年：

著者名：

キーワード：

ヒット件数：630 / 3741

KH Coderを用いた研究事例のリスト 3741件


※ 2020/6/21 現在 (961→1206→1646→2042→昨年2695件)

# KH Coder の情報

ホームページ <http://khcoder.net/>

The screenshot shows the official website for KH Coder. At the top is the logo 'KH Coder' with a blue, wavy background. Below it is a navigation bar with Japanese and English options. The main content area has a large banner for the book '社会調査のための計量テキスト分析' (Volume 2). To the right of the banner is a sidebar with a list of features: 'KH Coderの本ご好評発売中!', followed by a bulleted list: ✓ 分析の考え方, ✓ KH Coderの設計, ✓ 有効性の椂証, ✓ 応用事例, ✓ チュートリアル, ✓ マニュアル、etc. Below this is a section for 'Index' and 'お知らせ' (Announcement) which includes a link to a seminar. A '概要' (Summary) section follows, then a '機能紹介 (スクリーンショット)' (Function Introduction (Screenshot)) section with links to 'スクリーンショット集' and 'KH Coder 3の新機能'. The final section is 'KH Coderの入手' (How to Get KH Coder) with links to download pages for different versions.

## 参考書



PDFファイルをダウンロードすることもできます。  
※Windows版パッケージにはあらかじめ同梱してあります。

チュートリアル  
<http://khcoder.net/tutorial.html>



The screenshot shows a tutorial page for KH Coder 3. It features a large image of a computer keyboard. Below the keyboard, the text 'KH Coder 3 チュートリアル' is displayed. A presentation slide is shown with the title '漱石「こころ」を題材に【スライド版】'. The slide contains text and small images related to the book.

チュートリアル用データ  
2018/01/25

チュートリアルの実行に必要なデータファイルです。  
※Windows版パッケージには同梱してありますので、別途ダウンロードする必要はありません。

# 参考 — KH Coder の分析手順

<http://khcoder.net/diagram.html>



# 文の出現パターンと単語の出現パターン

【行】ある文中に出現する単語の数を要素とする (文ベクトル)

【列】全文中に出現する単語の数を要素とする (単語ベクトル)

h5	bun	部屋	ホテル	風呂	温泉	お部屋	スタッフ	立地	フロン	最高	浴場	お湯	露天風	感じ	夕食	バス	バイク	家族	場所	トイレ	子供	ペット	コンビ	良い
1	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
1	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
1	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
1	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	
1	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
1	6	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
1	7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
2	1	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
3	1	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	
3	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
3	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
3	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
4	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	

# 距離で「似てる」を図る

- Jaccard 距離: KHCoder で標準的な距離尺度
  - 1つ文書に含まれる語が少ないケースや,各語が一部の文書中にしか含まれていないケースに向いている →スパースなデータ分析向き

Jaccard 距離	ユークリッド距離	コサイン距離								
<ul style="list-style-type: none"> <li>• 1つの文書の中に語が1回出現した場合も10回出現した場合も単に「出現あり」と見なしてカウントした語と語の共起数を計算</li> <li>• 語Aと語Bのどちらも出現していない文書(0-0対)が沢山あっても語Aと語Bが類似しているとは見なさない</li> </ul>	<ul style="list-style-type: none"> <li>• 文書中における語の出現回数 (1,000語あたりの出現回数に調整) を計算</li> <li>• 1つひとつの文書が長く,多数の文書に含まれている語が多いデータ向き(各文書中の語の出現回数の大小が重要な場合)</li> </ul>	<ul style="list-style-type: none"> <li>• サイズの差までも見る場合向き</li> <li>• 傾きが似ているかどうかだけを見る場合向き</li> </ul>								
<table border="1"> <tr> <td>1</td><td>0</td></tr> <tr> <td>1</td><td><math>n_{11}</math></td><td><math>n_{10}</math></td></tr> <tr> <td>0</td><td><math>n_{01}</math></td><td><math>n_{00}</math></td></tr> </table> $J\text{S} = \frac{n_{11}}{n_{11} + n_{10} + n_{01}}$	1	0	1	$n_{11}$	$n_{10}$	0	$n_{01}$	$n_{00}$	$E d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum (x_i - y_i)^2}$	$\cos S(\mathbf{x}, \mathbf{y}) = \frac{\sum x_i y_i}{\sqrt{\sum x_i^2 \sum y_i^2}}$
1	0									
1	$n_{11}$	$n_{10}$								
0	$n_{01}$	$n_{00}$								

<http://mjin.doshisha.ac.jp/R/68/68.html>

# KH Coder—スクリーンショット


## 階層的クラスター分析

抽出語の階層的クラスター分析を行い、デンドログラムを表示します。抽出語だけでなくコーディング結果（コード）についても、同じように分析を行えます。




## 対応分析


同じく抽出語またはコードを用いての、対応分析です。



同時布置図



New! パブルプロット




複数の外部変数を用いた多重対応分析

## 自己組織化マップ


抽出語またはコードを用いての、自己組織化マップです。



クラスター色分け




頻度のプロット




U-Matrix

## 多次元尺度構成法（MDS）


同じく抽出語またはコードを用いての、多次元尺度構成法です。



2次元の解




New! クラスタリングと  
色分け



3次元の解

## 共起ネットワーク


抽出語またはコードを用いて、出現パターンの似通ったものを線で結んだ図、すなわち共起関係を線（edge）で表したネットワークを描く機能です。



共起の程度が非常に強いものだけを線で結んだ図



やや弱い共起関係も描画に含め、自動的にグループ分け（色分け）




出現数が多い語ほど大きく、また共起の程度が強いほど太い線で描画

## 文書のクラスター分析

文書の分類を行うクラスター分析です。



クラスター分析の結果画面



併合水準のプロット。クラスター数5付近から併合水準が急上昇。10でも少し上がっているので、この場合クラスター数は11が良いか。




文書のデンドログラム。左の棒グラフは各文書の長さをあらわす。なお、文書数が500を超える場合、デンドログラムは表示不可。

# KH Coder の主な分析手法

分析手法	解説
階層的クラスター分析	<ul style="list-style-type: none"><li>出現パターンの似た<b>単語同士をグルーピング(クラスタリング)</b>したもの</li><li>出現パターンは,ある単語がどの文書に出現したかといった単語ベクトルで表現</li><li>類似度計算には Jaccard, ユークリッド, コサイン距離を用い, いわゆる Ward法, 群平均法, 最遠隣法で樹形図を作成</li></ul>
多次元尺度構成法(MDS)	<ul style="list-style-type: none"><li>出現パターンの似た<b>単語同士を近くに置くよう図示</b>したもの</li><li>出現パターンは,ある単語がどの文書に出現したかといった単語ベクトルで表現</li><li>類似度計算には Jaccard, ユークリッド, コサイン距離を用い, クラシカル, Kruskal, Sammon 法のいずれかで2次元にプロット</li></ul>
対応分析	<ul style="list-style-type: none"><li>出現パターンの似た<b>単語や外部変数を近くに置くよう図示</b>したもの</li><li>単語と単語または外部変数が同時に出現した頻度をクロス集計し, それぞれの相関が最大になるような2変数で数値化し, 2軸上にプロット (PCAが元の情報をそのまま可視化するのに対し, 対応分析は似ているものを近くに表示する)</li><li>外部変数も同時にプロット可能</li></ul>
共起ネットワーク	<ul style="list-style-type: none"><li>同時に出現した<b>単語同士をネットワークで結んで図示</b>したもの</li><li>同時に出現したかといった共起の有無を集計し, ネットワークを作成</li><li>関係の強さ Jaccard 係数で評価, サブグラフは媒介性, クラスタリング精度(エッジ内の密度の高さ)を使って検出</li></ul>
自己組織化マップ	<ul style="list-style-type: none"><li>出現パターンの似た<b>単語同士を近くに集めて図示</b>したもの</li><li>ニューラルネットワークを利用して近い単語を集める方法で, 距離にはユークリッド距離を使い, クラスタリングは Ward法</li></ul>
文書のクラスター分析	<ul style="list-style-type: none"><li>似た<b>文書同士をグルーピング(クラスタリング)</b>したもの</li><li>各文書は, 文書中に出現する単語の有無でベクトル化した文書ベクトルで表現</li><li>類似度計算には Jaccard, ユークリッド, コサイン距離を使い, いわゆる Ward法, 群平均法, 最遠隣法で階層クラスタを作成</li></ul>


# データの取得方法

- <https://github.com/haradatm/lecture/tree/master/gssm-202107>




# ダウンロード方法

- Download ボタンをクリックするとダウンロードを開始



# 使い方—プロジェクトの作成


①メニューから「プロジェクト」「新規」を選択 (注1)



注1: 次回 KH Coderを起動した時は「新規」ではなく  
「開く」を選択します

注2: ②のファイル選択後,ここに「テキスト」等の  
選択項目が表示されるまで数分がかかります

②「参照」をクリックして  
「rakuten\_2019.xlsx」を開く




④説明「楽天トラベル」  
等を入力

⑤「OK」をクリック

# 使い方 — 前処理 (形態素解析)

①メニューから「前処理」「語の取捨選択」を選ぶ




②複合語など強制的に抽出したい語あればここに登録する (例:湯畠)

③削除語(ストップワード)など抽出したくない語あればここに登録する

④メニューから「前処理」「前処理の実行」を選ぶ


注1: EXCELファイルを読み込んで分析する場合、あらかじめ「---cell---」が入力されています

注2: メニューから「前処理」「複合語の検出」を選ぶと、複合語候補の一覧を出力できます



# 使い方 — 頻出語を確認する

- ①メニューから「ツール」「抽出語」「抽出語リスト」  
→右下「EXCEL出力」ボタンを選択



③「OK」をクリック


	A	B	C	D	E	F	G	H
1	抽出語	出現回数	抽出語	出現回数	抽出語	出現回数	抽出語	出現回数
2	部屋	4713	家族	677	非常	420		
3	思う	4080	バス	661	設備	418		
4	良い	4013	予約	638	湯	407		
5	利用	3550	旅行	629	接客	403		
6	宿泊	2731	清潔	618	高い	401		
7	風呂	2727	子供	616	静か	398		
8	ホテル	2726	初めて	613	掃除	397		
9	食事	2329	駐車	580	無料	391		
10	朝食	2126	過ごせる	571	新しい	372		
11	満足	2005	入れる	559	問題	368		
12	美味しい	1954	お世話	556	お湯	366		
13	温泉	1719	バイキング	555	施設	364		
14	お部屋	1553	丁寧	551	置く	361		
15	スタッフ	1454	過ごす	545	お願ひ	359		
16	対応	1407	素晴らしい	541	女性	357		
17	行く	1394	人	540	音	354		
18	立地	1334	古い	539	草津	353		

# 使い方－共起ネットワークの作成

①メニューから「ツール」「抽出語」「共起ネットワーク」を選ぶ


抽出語・共起ネットワーク

②「集計単位」として「文」を選んで「OK」をクリック



③品詞を選択する,例えば  
名詞, 名詞B, 名詞C, 未知語,  
形容詞, 形容詞B, 形容動詞, タグ

⑤「カラー」の箇所を「サブグラフ  
ラフ検出(modularity)」に変更



④「調整」をクリックして「強  
い共起関係ほど…」をチェック

# KH Coder の品詞体系

表 A.1 KH Coder の品詞体系


KH Coder 内の品詞名	茶筌の出力における品詞名
名詞	名詞一般（漢字を含む 2 文字以上の語）
名詞 B	名詞一般（平仮名のみの語）
名詞 C	名詞一般（漢字 1 文字の語）
サ変名詞	名詞-サ変接続
形容動詞	名詞-形容動詞語幹
固有名詞	名詞-固有名詞一般
組織名	名詞-固有名詞-組織
人名	名詞-固有名詞-人名
地名	名詞-固有名詞-地域
ナイ形容	名詞-ナイ形容詞語幹
副詞可能	名詞-副詞可能
未知語	未知語
感動詞	感動詞またはフィラー
タグ	タグ
動詞	動詞-自立（漢字を含む語）
動詞 B	動詞-自立（平仮名のみの語）
形容詞	形容詞（漢字を含む語）
形容詞 B	形容詞（平仮名のみの語）
副詞	副詞（漢字を含む語）
副詞 B	副詞（平仮名のみの語）
否定助動詞	助動詞「ない」「まい」「ぬ」「ん」
形容詞（非自立）	形容詞-非自立（「がたい」「つらい」「にくい」等）
その他	上記以外のもの

「KH Coder 3 リファレンス・マニュアル」  
P.14 より

注: どの品詞を選択すべきかは、分析対象のデータや分析目的により異なります。分析結果を確認しながら、適宜、適切な品詞選択を検討することが重要です

# 使い方—語句の前後文脈を表示する

- ①メニューから「ツール」「抽出語」「KWICコンコーダンス」を選ぶ



ダブルクリックで、さらに広い範囲の文脈を表示

②検索したい語 (例: 「風呂」) を入力して Enter キー



③「集計」をクリックするとコロケーション統計(右)を開く


④表示する語の品詞を選択 (例: 形容詞, 形容詞B, 形容動詞)

⑤「右合計」でソート

注: 共起ネットワーク上で「風呂」をクリックすると①②と同じ操作となります (V3以降)

# 使い方 — 外部変数(エリア)を利用する

①メニューから「ツール」「外部変数と見出し」「リスト」を開く





	B	C	D	E	F	G	H	I	J	K
2	01_登別		02_草津		03_箱根		04_道後			
3	食事	.059	湯畑	.081	食事	.070	温泉	.058		
4	部屋	.058	草津	.066	良い	.064	良い	.053		
5	良い	.055	温泉	.066	風呂	.056	利用	.052		
6	風呂	.053		.064	美味しい	.053	ホテル	.045		
7	宿泊	.045	風呂	.064	お部屋	.045	朝食	.044		
8	温泉	.043	食事	.056	満足	.044	道後	.042		
9	美味しい	.039	宿泊	.046	スタッフ	.041	宿泊	.041		
10	満足	.035	満足	.041	温泉	.040	満足	.034		
11	残念	.035	宿	.040	宿	.038	松山	.033		
12	行く	.031	美味しい	.040	露天風呂	.036	美味しい	.033		
13	05_湯布院		06_札幌		07_名古屋		08_東京			
14	食事	.070	札幌	.058	名古屋	.060	利用	.062		
15	美味しい	.067	思う	.056	利用	.056	部屋	.057		
16	宿	.064	部屋	.055	朝食	.053	ホテル	.056		
17	風呂	.063	ホテル	.053	ホテル	.052	駅	.046		
18	思う	.060	利用	.051	部屋	.048	便利	.044		
19	満足	.048	朝食	.051	駅	.038	朝食	.038		
20	料理	.045	宿泊	.046	便利	.031	立地	.035		
21	スタッフ	.043	立地	.039	立地	.029	近い	.034		
22	露天風呂	.042	広い	.031	フロント	.028	フロント	.032		
23	温泉	.042	近い	.031	近い	.027	近く	.026		
24	09_大阪		10_福岡							
25	利用	.068	利用	.059						
26	ホテル	.060	部屋	.056						
27	部屋	.054	ホテル	.049						
28	思う	.051	博多	.046						
29	大阪	.047	朝食							
30	朝食	.043	立地							
31	便利	.040								
32	立地	.040								
33	駅	.037								
34	近い	.031								

各エリアの特徴語を10件ずつ  
一覧 (数値は Jaccard係数)

# 使い方—対応分析による探索1

- ①メニューから「ツール」「抽出語」「対応分析」を選ぶ



# 使い方－コーディングルール


①メニューから「ツール」「文書」「文書検索」を選ぶ

②「参照」をクリックして  
「coding-rule.txt」を開く

③ダブルクリック

④「文」を選択

ダブルクリックで、さらに  
広い範囲の文脈を表示可能



※ コーディングルール: 語ではなくコンセプトを  
数えるための方法

coding-rule.txt の中身

\*ポジ

良い or 美味しい or 広い or 多い or 素晴らしい or  
嬉しい or 気持ちよい or 楽しい or 近い or 大きい or  
気持ち良い or 温かい or 早い or 優しい or 新しい or  
暖かい or 快い or 明るい or 美しい or 可愛い

\*ネガ

古い or 無い or 高い or 悪い or 小さい or 狹い or 少  
ない or 寒い or 遅い or 熱い or 欲しい or 暑い or 冷  
たい or 遠い or 臭い or 暗い

\*風呂1-2

<>風呂-->1 | <>風呂-->2


\*風呂4-5

<>風呂-->4 | <>風呂-->5

外部変数

# 使い方 — 対応分析による探索2

①メニューから「ツール」「コーディング」「対応分析」を選ぶ



# 使い方－クロス集計



①メニューから「ツール」「コーディング」「クロス集計」を選ぶ

②「参照」をクリックして  
「coding-rule.txt」を開く

④「集計」を  
クリック

③「エリア」を選択

⑤「すべて」をクリック



# 課題 — 数値評価と口コミの傾向比較

- ・コーディングルール「coding-rule.txt」中の「風呂1-2」「風呂4-5」を参考に、「総合1-2」「総合4-5」のルールを定義したコーディングルール「coding-rule\_new.txt」を作成してください
- ・前ページで紹介したクロス集計を用いて,エリアごとのポジ・ネガ意見の傾向と,数値評価の総合点を比較し,違いについて考察してください
- ・形式: PPT(PDF), 提出先: manaba, 期限: 次回 7/17 18:20


# 操作例 — 数値評価と口コミの傾向比較

①メニューから「ツール」「コーディング」「クロス集計」を選ぶ


②「参照」をクリックして  
「coding-rule\_new.txt」を開く

④「集計」を  
クリック

③「エリア」を選択



⑤「すべて」をクリック



# 実習 + Q&A

# 次回の演習用データ

データファイル名	件数	データセット	備考
rakuten_2019.xlsx	10,000	<ul style="list-style-type: none"><li>レジャー+ビジネスの 10エリア</li><li>エリアごと 1,000件をサンプリング</li><li>EXCEL 形式 (シート名「2019」)</li></ul>	<ul style="list-style-type: none"><li>本講義の全体を通して利用する</li></ul>
rakuten_2020.xlsx	8,518	<ul style="list-style-type: none"><li>レジャー+ビジネスの 10エリア</li><li>エリアごと 1,000件 (登別,草津,由布院は 1,000件以下のため全数, それ以外はランダムサンプリング)</li><li>EXCEL 形式 (シート名「2020」)</li></ul>	<ul style="list-style-type: none"><li>演習用 (3~4日目)</li></ul>
covid_2020.xlsx	30,000	<ul style="list-style-type: none"><li>Search API で取得した 2020/4/24~6/30 のハッシュタグ「#新型コロナ」のツイート</li><li>データ分布を保持して,3万件をサンプリング</li><li>EXCEL 形式 (シート名「30000」)</li></ul>	<ul style="list-style-type: none"><li>演習用 (3~4日目)</li></ul>

※ 自身の業務課題を題材にしても構いませんが、個人情報や機密情報など**守秘義務に特に留意**してください。

# グループ分け

グループ1	201940108
	202040051
	202040055
	202040074
	202040077
グループ2	201945014
	202040057
	202040063
	202040080
	MSI
グループ3	202040052
	202040062
	202040070
	202040072
	202040170

グループ4	201940109
	202040058
	202040060
	202040068
	202040069
グループ5	201940015
	201947523
	202040059
	202040066
	202040073
グループ6	201840109
	201940129
	202040064
	202040078
	202040079

グループ7	202040071
	202040076
	202040409
	202040413
グループ8	202020027
	202020051
	202040067
	202040075
グループ9	202040053
	202040054
	202040056
	202040061

# 参考書

## (KH Coder)

- [1] 横口耕一. 社会調査のための計量テキスト分析—内容分析の継承と発展を目指して  
【第2版】 KH Coder オフィシャルブック. ナカニシヤ出版, 2020.
- [2] 横口耕一. テキスト型データの計量的分析—2つのアプローチの峻別と統合—. 理論  
と方法, 数理社会学会, 2004, 19(1): 101-115.
- [3] 牛澤賢二. やってみよう テキストマイニング—自由回答アンケートの分析に挑戦!.  
朝倉書店, 2019

## (Windows環境によるデータ収集方法の参考に)

- [4] テキストマイニングソフトを利用した新未来洞察手法の研究. 第10分科会, (財)市場  
創造研究会. [http://www.shijo-sozo.org/news/第10分科会\\_1.pdf](http://www.shijo-sozo.org/news/第10分科会_1.pdf)

# 参考書

## (Rを使った参考書)

- [5] 金明哲. "テキストデータの統計科学入門." 岩波書店, 2009.
- [6] 石田基広. "RMeCabによるテキスト解析. Rによるテキストマイニング入門." 森北出版, 2008, 51-82.

## (他のツールを使った参考書)

- [7] 那須川哲哉. "テキストマイニングを使う技術/作る技術: 基礎技術と適用事例から導く本質と活用法." 東京電機大学出版局, 2006.
- [8] 上田隆穂, 黒岩祥太, 戸谷圭子. "テキストマイニングによるマーケティング調査." 講談社, 2005.

## (統計解析を中心とした参考書)

- [9] 前田忠彦; 山崎誠. 言語研究のための統計入門. くろしお出版株式会社, 東京, 2013.